

Припиніть платити за трафік, якого не було

Багатоміткове виявлення невалідного трафіку — повна архітектура, пояснена для всіх

Як рушій, натхненний роботою мозку, читає кожен рекламну подію на багатьох часових масштабах, називає точний вид невалідного трафіку, показує свої докази й рекомендує дію — жодного разу тихо не блокуючи публішера й не утримуючи виплату. Написано так, щоб кожен крок був зрозумілий нефахівцю.

Документ	Архітектурний і технічний огляд
Продукт	Jneopallium Ad-Fraud Guardian (модуль advertising-fraud)
Модель	advertising-fraud 1.0.0 · macro-F1 $\approx$ 0.97
Режим безпеки	ADVISORY / SHADOW (лише рекомендації)
Автор	Дмитро Раковський — Харків, Україна
Дата	23 червня 2026
Аудиторія	Маркетологи, ad-ops, антифрод-команди, інженери, новачки
Ліцензія	BSD 3-Clause

Зміст

1. Стислий огляд — версія на одну сторінку
2. Проблема: де витікає рекламний бюджет
3. Головна ідея: назви фрод, покажи докази
4. Платформа в основі: фреймворк Jneorallium
5. Огляд архітектури: восьмирівнева мережа
6. Що він бачить: канонічна рекламна подія
7. Десять родин фроду, які він оцінює
8. Сигнали на багатьох годинниках
9. Від сирої події до вердикту: конвеєр доказів
10. Навчена модель і готова до розгортання мережа
11. Безпека й приватність за задумом
12. Наскільки він хороший? (і наскільки чесний)
13. Де він вписується у ваш стек
14. Словник для нефахівців

1 Стислий огляд

Велика частка цифрової реклами оплачується, але її ніколи не бачить справжня зацікавлена людина. Боти клікають по рекламі, клік-ферми виробляють інсталяції, шахраї привласнюють заслугу за конверсії, які сталися б і так, а «зроблений для реклами» інвентар поглинає бюджет. Галузеві оцінки визначають світові втрати в **десятки мільярдів доларів на рік**.

Jneopallium Ad-Fraud Guardian оцінює кожну рекламну подію — ставку, покази, клік, інсталяцію, постбек — і відповідає на три питання, на які не може відповісти єдиний «бал фроду»: **який** це вид невалідного трафіку, **чому** (докази) і **що робити** (пропорційна, кандидатна дія). Він **багатомітковий**: одну подію можна позначити кількома мітками одразу, кожна зі своєю каліброваною ймовірністю.

Одне речення, яке варто запам'ятати

Він не видає розпливчастий «% ризику». Він каже «це схоже на click injection та attribution hijack, ось докази, рекомендую HOLD_PAYOUT на перевірку» — і ніколи не виконує цю дію сам.

Найважливіше: він працює **рекомендаційно** (SHADOW, потім ADVISORY): радить, але ніколи автоматично не блокує паблішера, не утримує виплату й не звинувачує людину. Він приватний за задумом — ідентифікатори хешуються перед навчанням, а сирі IP, точна геолокація й рядки user-agent ніколи не експортуються. Це робить його безпечним поруч із наявними вимірюванням і білінгом.

2 Проблема: де витікає рекламний бюджет

Єдиного вердикту «фрод / не фрод» недостатньо

Невалідний трафік — не одне явище. Це родина дуже різних поведінок, кожна з яких потребує іншої відповіді та іншого власника:

- **Боти** — автоматизовані кліки й перегляди без людини.
- **Клік-ферми та мотивовані інсталяції** — справжні, але мотивовані люди, яким платять за клік чи інсталяцію і які ніколи не стають реальними клієнтами.
- **Фрод атрибуції** — click spam і click injection, що крадуть *заслугу* за конверсію, яка сталася б і так, тож платять не тому партнеру.
- **Підробка подій** — підроблені чи повторені покази, кліки й постбеки.
- **Підробка інвентаря / шляху постачання** — паблішер видає себе за преміум-інвентар, яким не є (невідповідності ads.txt / sellers.json).

Інструмент, що повертає одне число — «73% фроду» — не скаже аналітику, чи утримати виплату (фрод атрибуції), знизити цінність трафіку (низька якість), обмежити джерело (боти) чи нічого не робити (справжній випадковий клік). Дорогі помилки виникають, коли все це трактують однаково.

Чому це складно, чесно

Докази цих родин живуть на **різних часових масштабах**: підроблений підпис — миттєвий, часова аномалія click injection — посесійна, шаблон клік-ферми проявляється за хвилини, а правда про *якість* — чи стала інсталяція утриманим платним користувачем? — приходить лише за дні як дані про утримання, повернення та чарджбеки. Жоден швидкий поріг не бачить усього цього.

3 Головна ідея: назви фрод, покажи докази

Guardian запозичує форму в мозку: багато спеціалізованих «нейронів», що працюють на різних швидкостях годинника, кожен виробляє один вид доказів, живлячи фінальний корелятор, який поєднує все в названі, каліброві вердикти. Три рішення роблять його комерційно переконливим:

- **Багатоміткова, не один бал.** Десять незалежних міток фроду, кожна зі своєю каліброваною ймовірністю, тож правильна дія прив'язується до правильної проблеми.
- **Спершу докази.** Кожен вердикт несе сигнали, що долучилися, і причину, зрозумілу людині, тож аналітик — або аудитор, або апеляція паблішера — бачить **чому**.
- **Рекомендаційний за побудовою.** Він видає лише **кандидатні** дії. Утримання грошей чи блокування партнера потребує валідації на власних даних, юридичного перегляду й шляху апеляції — ніколи лише моделі.

Чому рекомендаційність — це перевага, а не обмеження

Помилково утримати виплату законному паблішеру — це позов і зруйноване партнерство. Система, що рекомендує й пояснює, а спускати курок дає людині, — єдина, яку мережа може справді розгорнути в масштабі.

4 Платформа в основі: фреймворк Jneopallium

Guardian — це один застосунок **Jneopallium**, Java-фреймворку для біологічно обґрунтованих нейронних мереж (опубліковано в **International Journal of Science and Research**, 2024). Три його ідеї пояснюють, чому він пасує до цієї задачі.

1. Типізовані сигнали — зміст, а не лише числа

Ставка, клік, постбек і повернення — це **різні види сигналів** із різним змістом і терміновістю. Рушій спрямовує кожен до потрібного фахівця й зберігає докази аж до вердикту — саме це дає кожній рекомендації нести причину.

2. Багато годинників — миттєві перевірки, повільна правда

Jneopallium обробляє швидкі сигнали щотакту, а повільніший контекст — кожні N тактів. Перевірки цілісності спрацьовують миттєво; поведінкова агрегація повільніша; відкладена правда про якість трафіку (утримання, повернення, чарджбеки) приходить найповільніше. Один нейрон може зважити миттєву невдачу підпису проти багатоденного результату якості в одному цілісному судженні.

3. Однопризначені нейрони, що замінюються

Кожен нейрон виконує одну роботу й може бути оновлений чи замінений для конкретного розгортання, не торкаючись решти. Потужність додається додаванням **рівнів і нейронів**, а не вкладанням логіки в одне місце — саме так цю модель нещодавно розширили (див. розділ 10).

5 Огляд архітектури: восьмирівнева мережа

Події течуть в один бік через дедалі розумніші рівні; з іншого боку виходить пояснювана рекомендація. Готова до розгортання мережа — це **8 рівнів із 22 нейронів над 21 ознакою**:

Рівень	Розмір	Завдання, простими словами
0 — Вхід	—	Прийом багатоджерельних рекламних подій (ставки, покази, кліки, постбеки...)
1 — Цілісність подій	4	Підпис/повтор/час, людська взаємодія, порядок сесії, атрибуція
2 — Сутність / граф / якість	3	Базові лінії паблішерів, граф фанату клік-ферм, відкладена якість
3 — Поведінкові докази	4	Специфічні для родини докази, що розділяють схожі види фроду
4 — Взаємодія ознак	8	Нелінійні комбінації доказів (один нейрон на одиницю)
5 — Навчена кореляція	1	Поєднує все в десять каліброваних ймовірностей міток
6 — Запобіжник відповіді	1	Відображає ймовірності на пропорційну кандидатну дію (рекомендація)
7 — Результат	1	Видає аудитоване рішення: мітки, докази, причина, дія

6 Що він бачить: канонічна рекламна подія

Усе нормалізується в одну версіоновану **канонічну подію**, що зберігає і час події, і час прийому, та підтримує п'ятнадцять типів подій по всій воронці:

BID_REQUEST · IMPRESSION · VIEWABLE_IMPRESSION · CLICK · LANDING
INTERACTION · INSTALL · REGISTRATION · PURCHASE · POSTBACK
REFUND · CHARGEBACK · UNINSTALL · RETENTION · PAYOUT

Кожна подія несе поля цілісності (підписи, нонси, атестація), поведінкові докази (час перебування, динаміка вказівника, лічильники сесії), контекст постачання (ads.txt / sellers.json) та **відкладені результати якості** (утримання, повернення, чарджбек). Ідентифікатори псевдонімі: сирі персональні ідентифікатори хешуються HMAC, перш ніж модель їх побачить, а відсутнє значення тримається окремо від значення нульового ризику.

7 Десять родин фроду, які він оцінює

Мітка	Значення простою мовою
bot	Автоматизовані, нелюдські кліки чи перегляди
incentivized	Справжні, але мотивовані користувачі; низька подальша цінність
clickFarm	Скоординовані ферми людей/пристроїв, що виробляють залученість

eventSpoofing	Підроблені чи повторені покази / кліки / постбеки
clickSpam	Масові низькоякісні кліки, що претендують на широку атрибуцію
clickInjection	Клік, запущений у момент інсталяції, щоб украсти атрибуцію
attributionHijack	Привласнення заслуги за конверсію, що сталася б і так
inventorySpoofing	Спотворення паблішера / шляху постачання (ads.txt / sellers.json)
accidentalOrLowValue	Справжній, але випадковий чи низькоцінний трафік — не зловмисний
unknownSuspicious	Аномальний трафік, який модель ще не може назвати

Зверніть увагу на `accidentalOrLowValue` та `unknownSuspicious`: модель створена казати *«це дивно, але не обов'язково фрод»*, а не перезвинувачувати. Саме ця відмінність тримає її придатною без руйнування стосунків із паблішерами.

8 Сигнали на багатьох годинниках

Кожна родина сигналів оголошує, як часто її обробляють — ідея «багатьох годинників» втілена конкретно. Швидкі детерміновані докази йдуть щотакту; правда про якість приходить найповільніше:

Родина сигналів	Каданс (loop / epoch)	Що захоплює
Цілісність, ставка, покази, клік, постбек	1 / 1	Швидкі детерміновані докази
Агрегація взаємодії користувача	1 / 2	Поведінкова агрегація
Послідовність сесії й атрибуція	1 / 5	Перевірки причинного ланцюга
Базова лінія сутності	2 / 1	Адаптивні базові лінії паблішерів
Оновлення графа кластерів	2 / 3	Рухомий граф фанауту клік-ферм
Якість трафіку	2 / 5	Відкладені докази якості
Утримання / повернення / білінг	2 / 10	Повільна відкладена правда
Дрейф моделі	2 / 60	Каданс моніторингу

Фізична тривалість такту — це конфігурація розгортання; це *семантичні* каданси планувальника, що дають одній моделі реагувати миттєво й водночас враховувати докази, доступні лише за дні.

9 Від сирої події до вердикту: конвеєр доказів

Проведемо одну подію крізь мережу:

- 1. Рецептори цілісності (Рівень 1)** перевіряють підпис, нонс, узгодженість клієнт/сервер і порядок сесії та виробляють швидкі докази ризику.

2. **Сутність, граф і якість (Рівень 2)** порівнюють подію з базовими лініями паблішерів, оновлюють рухомий граф фанату пристроїв/акаунтів і додають відкладені докази утримання/повернення.
3. **Поведінкові нейрони (Рівень 3)** кожен видає один специфічний для родини сигнал — обсяг кліків (спам), час конверсії (injection), шаблон мотивації (incentivized), низькоцінну якість — що й розділяє види фроду, які інакше виглядають однаково.
4. **Нейрони взаємодії (Рівень 4)** утворюють нелінійні комбінації доказів, тож фінальний етап може виразити правила на кшталт «висока атрибуція *і* низька якість *і* високий темп кліків».
5. **Нейрон кореляції (Рівень 5)** поєднує все в десять **каліброваних** ймовірностей — по одній на мітку фроду.
6. **Запобіжник відповіді (Рівень 6)** відображає ці ймовірності на пропорційну **кандидатну** дію, а **рівень результату (Рівень 7)** видає аудитоване рішення з доказами й причиною.

Смуги відповіді → кандидатні дії

$\log(0.0-0.30) \rightarrow \text{ALLOW/LOG} \cdot \text{review}(0.30-0.60) \rightarrow \text{REVIEW} \cdot \text{кандидат на rate-limit}(0.60-0.75) \cdot \text{кандидат на hold-payout}(0.75-0.90) \cdot \text{ескалація аналітику}(0.90-1.0)$. Кожна дія — *кандидат*; жодна не виконується автоматично.

10 Навчена модель і готова до розгортання мережа

Навчання не зупиняється на наборі ваг — воно видає **власне готову до розгортання мережу JNeopallium**: вісім файлів рівнів плюс опис, із вбудованими навченими каліброваними головами, що посилаються на конкретні класи часу виконання. Поточна мережа відображає нещодавнє навмисне оновлення, що різко підняло якість (див. Звіт про тестування):

Складова	Що додає
21 ознака	8 базових ризиків + 5 поведінкових + 8 нелінійних одиниць взаємодії
Рівень поведінкових доказів	Однопризначені нейрони, що розділяють схожі родини фроду
Рівень взаємодії ознак	Нелінійний прихований рівень (доданий як окремий рівень, нейрон на одиницю)
Припасовані каліброві голови	Класово-зважені логістичні голови зі справжнім Platt-калібруванням
Пороги з урахуванням вартості	Робочі точки за очікуваною користю (хибні спрацювання коштують грошей)

Оскільки навчені голови, калібрування й пороги — усе всередині файлів мережі, **те, що навчили, — це саме те, що працює**; між моделлю й розгорнутим скорером немає кроку перекладу.

11 Безпека й приватність за задумом

1. **Рекомендаційно / тінь за замовчуванням.** Запобіжник відповіді видає лише кандидатні дії; автоматичне відхилення білінгу, утримання виплат, блокування акаунтів чи звинувачення

структурно вимкнені, доки не існує окремого процесу валідації, юридичного перегляду й апеляції.

2. **Без звинувачення людини.** Модель видає *докази* невалідного трафіку; вона ніколи не стверджує, що названа особа навмисно скоїла фрод.
3. **Збереження приватності.** Ідентифікатори пристроїв і акаунтів псевдонімізуються (HMAC) перед навчанням; сирі IP, точна геолокація й рядки user-agent ніколи не експортуються; відсутнє значення тримається окремо від нульового ризику.
4. **Оцінка без витоку.** Дані розбиваються за сценарієм, епізодом кампанії й детермінованим блоком реплік — ніколи за випадковим рядком — з ворожим холдаутом, тож заявлена якість не завищена майже-дублікатами.

12 Наскільки він хороший? (і наскільки чесний)

На вбудованому еталонному корпусі модель сягає **macro-F1 $\approx$ 0.97** по десяти мітках, де більшість родин на рівні або близько ідеального розділення з каліброваними ймовірностями. Нещодавнє оновлення підняло macro-F1 з **0.66 до 0.97**, додавши рівні поведінкових доказів і взаємодії та виправивши калібрування й пороги.

Прочитайте це чесно

Ця оцінка — на детермінованому симуляторі плюс слабких публічних метаданих, з оцінкою без витоку. Вона доводить конвеєр і розділення міток — це НЕ твердження про реальну точність, яку треба заслужити на власному розміченому промисловому трафіку. До того часу модель лишається SHADOW/ADVISORY. Звіт про тестування прямо про це говорить.

13 Де він вписується у ваш стек

Guardian стоїть *поруч* із вашим наявним конвеєром як рекомендаційний скорер, а не в критичному шляху показу:

```
ad server / SSP / DSP / MMP -> канонічні рекламні події
-> Ad-Fraud Guardian (оцінює кожну подію, рекомендаційно)
    -> рішення: мітки + докази + кандидатна дія
-> ваш SIEM / сховище даних / перегляд білінгу / черга аналітика
```

Він розгортається локально, як HTTP-служба скорингу або розподілено; читає потік подій у стилі Kafka чи прямий канал; працює у трьох формах (один процес, HTTP-кластер, gRPC), тож пасує і пілоту на ноутбучі, і корпоративному потоку подій. Оскільки кореляція ведеться за часом події, запізнілі й невідповідні події все одно потрапляють у правильне місце.

14 Словник для нефакхівців

Термін	Значення простою мовою
Невалідний трафік (IVT)	Рекламні події без справжньої зацікавленої людини
Багатоміткова	Одна подія може нести кілька незалежних міток фроду одразу

Атрибуція	Визначення, який клік/партнер отримує заслугу (і оплату) за конверсію
Click injection	Запуск фейкового кліку в момент інсталяції, щоб украсти заслугу
Постбек	Серверне повідомлення, що підтверджує конверсію
ads.txt / sellers.json	Публічні файли, що декларують, хто має право продавати рекламне місце
Калібрування	Зробити так, щоб бал 0.9 справді означав ~90% імовірності
Рекомендаційно / тінь	Система радить; рішення приймають люди. Сама не блокує й не утримує
Псевдонімно / HMAC	Ідентифікатори хешуються, тож модель ніколи не бачить сирих персональних даних
Macro-F1	Якість виявлення, усереднена порівну по всіх десяти мітках фроду

Jneopallium Ad-Fraud Guardian · модуль advertising-fraud. Архітектурна стаття для технічних і нетехнічних читачів. Режим безпеки: ADVISORY / SHADOW. Ліцензія: BSD 3-Clause.