

Повний звіт про тестування

Багатоміткове виявлення невалідного трафіку — результати, оновлення, що їх підняло, і чесне прочитання

Що тестували, як воно показало себе, що змінило нещодавнє оновлення і — прямо й наперед — що саме результати доводять, а що ні. Написано так, щоб нефахівець міг упевнено прочитати кожне число.

Документ	Звіт про верифікацію та тестування
Продукт	Jneopallium Ad-Fraud Guardian (модуль advertising-fraud)
Модель	advertising-fraud 1.0.0-reference-advisory
Заголовок	macro-F1 0.66 → 0.97 після навмисного оновлення моделі
Результат	Усі перевірки пройдено (еталонний корпус); 12/12 тестів Java
Автор	Дмитро Раковський — Харків, Україна
Дата	23 червня 2026
Ліцензія	BSD 3-Clause

Зміст

1. Стислий огляд результатів
2. Що ми тестували і навіщо
3. Тестове середовище
4. Метрики простою мовою
5. Якість моделі — на мітку, до і після
6. Оновлення, що підняло оцінку
7. Калібрування — чи чесні ймовірності?
8. Детермінований процес і аудит витоку
9. Готова до розгортання мережа і набір тестів Java
10. Чесні обмеження (прочитайте уважно)
11. Загальний вердикт і готовність
12. Словник

1 Стислий огляд результатів

Ad-Fraud Guardian перевірено на чотирьох незалежних рівнях: **якість моделі** (наскільки добре вона розділяє кожну родину фроду), **калібрування** (чи чесні її ймовірності), **цілісність процесу** (без витоку, відтворено) та **середовище виконання** (готова мережа завантажується, набір Java проходить). Усі перевірки пройдено, а нещодавнє навмисне оновлення різко підняло головне число.

Рівень тестів	Що перевіряє	Результат
Якість моделі	Точність / повнота / F1 на мітку, macro-F1	macro-F1 $\approx$ 0.97 (було 0.66)
Калібрування	Чи означає бал 0.9 ~90% імовірності	Справжнє Platt на мітку (було тотожність)
Процес	Розбиття без витоку, відтворюваність	Пройдено — аудит чистий, детерміновано
Виконання	Пакет завантажується, тести Java	Пройдено — 12/12 тестів Java зелені

Найважливіше речення цього звіту

Майже ідеальні оцінки — на детермінованому симуляторі плюс слабких публічних метаданих, з оцінкою без витоку. Вони доводять конвеєр і розділення міток — це НЕ твердження про реальну точність, яку треба заслужити на власному розміченому промисловому трафіку. До того часу модель лишається SHADOW/ADVISORY. Ми зазначаємо це тут, на початку, навмисно.

2 Що ми тестували і навіщо

Продукт проти невалідного трафіку заслуговує довіру, коли його тестують так, як він використовуватиметься — не просто «чи запускається», а «чи називає правильний фрод, чи калібрує впевненість і чи відмовляється перезвинувачувати». Тому верифікація багаторівнева:

- **Кожна родина фроду** — на відкладених подіях, чи відділяє кожна з десяти міток свій вид фроду від усього іншого і чи достатньо висока точність, щоб діяти?
- **Ймовірності** — чи справді 0.9 означає приблизно 90%, тож аналітики й пороги можуть їм довіряти?
- **Процес** — чи розбиття без витоку (жоден ідентифікатор не перетинає train/test) і чи запуск відтворюваний для фіксованого сіда?
- **Середовище виконання** — чи завантажується експортована мережа з перевіреними контрольними сумами і чи проходить набір тестів Java?

3 Тестове середовище

Пункт	Значення
Платформа	Багатомодульний проєкт Maven Jneopallium (master + worker)
Середовище виконання	Скорер на Java 17+; процес на Python 3 (без сторонніх пакетів)

Модель під тестом	advertising-fraud, 1.0.0-reference-advisory
Задача	Багатоміткова: десять незалежних міток невалідного трафіку
Мережа	8 рівнів, 22 нейрони, 21 ознака (8 базових + 5 доказів + 8 взаємодій)
Режим безпеки	ADVISORY / SHADOW; AUTOMATED_ACTION_READY = false
Еталонна команда	python scripts/demo-ad-fraud/run_all.py --offline
Детермінізм	Відтворювано для фіксованого сіда: та сама команда → ті самі метрики

4 Метрики простою мовою

«Приклад» — це одна рекламна подія, яку модель позначає. Метрики класифікації:

Метрика	Значення простою мовою	Найкраще
Точність	Зі подій, позначених міткою, скільки справді її мали	1.0 (без хибних тривог)
Повнота	Зі справжніх випадків мітки скільки зловлено	1.0 (нічого не пропущено)
F1	Єдина справедлива суміш точності й повноти	1.0
Macro-F1	F1, усереднений порівну по всіх десяти мітках	1.0
PR / ROC-AUC	Наскільки добре бал *ранжує* фрод над не-фродом	1.0
Похибка калібрування	Наскільки бал 0.9 далекий від справжніх 90%	0.0

Ранжування проти порога — чому важливі обидва

Голова може ранжувати ідеально (AUC 1.0), але мати поганий F1, якщо її поріг рішення неправильний. Попередня модель провалилася саме так на двох мітках; оновлення виправило пороги й калібрування та додало докази, яких бракувало конфліктним міткам.

5 Якість моделі — на мітку, до і після

Кожну мітку оцінено на відкладеному розбитті без витоку (включно з ворожим холдаутом). Нещодавнє оновлення покращило або втримало кожну мітку; macro-F1 зріс із **0.66 до 0.97**:

Мітка фроду	F1 до	F1 після	Точність після	Повнота після
bot	1.00	1.00	1.00	1.00
eventSpoofing	1.00	1.00	1.00	1.00

attributionHijack	1.00	1.00	1.00	1.00
unknownSuspicious	1.00	1.00	1.00	1.00
clickInjection	0.25	1.00	1.00	1.00
inventorySpoofing	0.25	1.00	1.00	1.00
incentivized	0.67	1.00	1.00	1.00
clickFarm	0.67	1.00	1.00	1.00
clickSpam	0.29	0.98	0.95	1.00
accidentalOrLowValue	0.44	0.69	0.52	1.00

macro-F1: 0.656 → 0.966. Кожну раніше зламану голову виправлено. Єдина слабка точка, що лишилася, `accidentalOrLowValue` (0.69), — це навмисно розмита *об'єднана* мітка: випадкові кліки, низькоконверсійний трафік і мотивовані інсталяції — усе зведено в неї, тож вона внутрішньо складніша, і підняти її вище потребує власних міток, а не більше архітектури.

6 Оновлення, що підняло оцінку

Стрибок стався завдяки діагнозу, а не вгадуванню. Попередня модель провалювалася двома різними способами, кожен виправлено конкретною зміною:

Провали порогів / калібрування (дешево виправити)

`clickInjection` та `inventorySpoofing` ранжували ідеально (AUC 1.0), але мали F1 0.25, бо їхній поріг рішення позначав *усе*, а калібрування було пустим. Виправлення порогів на мітку, додавання справжнього Platt-калібрування й надання цим ворожим родинам покриття в навчанні підняли обидві до 1.0.

Конфліктні мітки (потрібна нова потужність моделі)

`clickSpam` мала тотожну голову з `attributionHijack`, а `incentivized` — із `clickFarm`: 8 базових ознак не могли відрізнити схожих. Це виправили два нові рівні: **рівень поведінкових доказів** (однопризначені нейрони, що видають ознаки обсягу кліків, часу конверсії, мотивації й низької цінності) та **нелінійний рівень взаємодії ознак**. Разом із класово-зваженими, L2-регуляризованими логістичними головами конфліктні мітки розділилися.

Покращення	Ефект
Пороги на мітку з урахуванням вартості	Виправили <code>clickInjection</code> / <code>inventorySpoofing</code> (0.25 → 1.0)
Справжнє Platt-калібрування (було тотожність)	Чесні ймовірності; нижча похибка калібрування
Припасовані класово-зважені логістичні голови	Замінили одноразове правило різниці середніх
+5 поведінкових ознак + новий рівень	Розділили <code>clickSpam</code> , <code>incentivized</code> , низьку цінність
+8 нелінійних одиниць взаємодії (новий рівень)	Захопили комбінації доказів I/АБО
Більший збалансований корпус	Стабільне припасування й калібрування для кожної мітки

7 Калібрування — чи чесні ймовірності?

Оцінка впевненості корисна, лише якщо означає те, що каже. Попередня модель **не** застосовувала калібрування (стверджувала, що тестує Platt / isotonic / temperature, але застосовувала тотожність). Поточна модель припасовує **справжнє Platt-масштабування на мітку** на відкладеному розбитті калібрування, тож 0.9 справді означає приблизно 90%. Саме це робить смуги відповіді — і будь-який майбутній поріг ємності перегляду — гідними довіри.

8 Детермінований процес і аудит витоку

Числа якості мають сенс, лише якщо оцінка чесна. Процес це забезпечує:

- **Розбиття без витоку** — за сценарієм, епізодом кампанії й детермінованим блоком реплік, із ворожим холдаутом. Аудит **провалює запуск**, якщо будь-який ідентифікатор пристрою / кліку / кампанії перетинає межі розбиття.
- **Відтворювано** — для фіксованого сіда та сама команда дає той самий корпус, ті самі метрики й той самий експортований пакет.
- **Перевірено приватність** — ідентифікатори HMAC-псевдонімізовані; сири IP, точна гео й user-agent ніколи не експортуються; відсутнє окреме від нуля.

9 Готова до розгортання мережа і набір тестів Java

Запуск також створив і перевірів **готову до розгортання мережу JNeopallium**: вісім файлів рівнів плюс `model-descriptor.json`, що описує 8 рівнів, 22 справжні нейрони й 21 ознаку, де кожен нейрон посилається на конкретний клас часу виконання, з вбудованими каліброваними головами й нелінійним прихованим рівнем. Середовище виконання Java завантажує цей пакет, перевіряє контрольні суми й обчислює прихований рівень — тож **протестований артефакт — це той самий артефакт, що розгортається**.

Набір тестів Java — **12 тестів**, що охоплюють покриття типів подій, каданси сигналів, детерміновані правила цілісності, поведінку заморожування базової лінії й TTL графа, рекомендаційний запобіжник відповіді, завантаження пакета з перевіркою контрольних сум, структуру опису / рівнів, процесори за інтерфейсом і HTTP-службу скорингу — **проходить 12 / 12**.

10 Чесні обмеження (прочитайте уважно)

1. **Еталонний корпус синтетичний плюс слабкі мітки**. Детермінований симулятор постачає класи фроду, що не мають публічних міток, доповнені слабкими публічними метаданими. Майже ідеальні оцінки підтверджують конвеєр і розділення міток — не реальну точність.
2. **Реальну точність треба заслужити на власних мітках**. Справжні промислові твердження потребують підтверджених чарджбеків, рішень MMP щодо фроду й вердиктів аналітиків, із валідацією вперед у часі та на небачених паблішерах, лімітами фінансової вартості хибних спрацювань і задокументованим переглядом обробки даних.
3. **Лише рекомендації, і ніколи не звинувачення**. Модель видає докази невалідного трафіку й кандидатні дії; вона ніколи не блокує, не утримує гроші й не стверджує, що названа особа скоїла фрод. `AUTOMATED_ACTION_READY` лишається хибним, доки немає валідації, юр. перегляду й апеляції/відкату.

Чому ми починаємо із застереження

Продукт проти фроду, що розмиває межу між доказами конвеєра й польовою точністю, не можна довірити поряд із рішенням про виплату. Чесність — частина продукту: кожна рекомендація несе свої докази, а кожне твердження звіту несе свій обсяг.

11 Загальний вердикт і готовність

Ad-Fraud Guardian проходить кожен тест на кожному рівні на еталонному корпусі, а нещодавнє оновлення підняло macro-F1 з 0.66 до 0.97. Десять міток розділяються з чесними, добре каліброваними ймовірностями; процес без витоку й відтворюваний; готова мережа завантажується, а набір Java зелений; стега безпеки (рекомендації, без звинувачення) збережена впродовж усього.

Готовність: **ENGINEERING_READY, SHADOW_READY, ADVISORY_READY = true;**

AUTOMATED_ACTION_READY = false. Система готова до наступного етапу — офлайн-відтворення й тінюва валідація на реальному власному трафіку, єдиного, що може перетворити ці сильні докази конвеєра на твердження про польову точність.

12 Словник

Термін	Значення
Багатоміткова	Кілька незалежних міток фроду можуть бути істинними для однієї події
Точність / повнота	Частка правильних позначок / частка зловлених справжніх випадків
Macro-F1	Якість виявлення, усереднена порівну по десяти мітках
AUC	Наскільки добре бал ранжує фрод над не-фродом, незалежно від порога
Калібрування	Чи означає оцінка впевненості те, що каже
Platt-масштабування	Стандартний спосіб перетворити сирі бали на чесні ймовірності
Витік	Коли майже-дублікати просочуються між train/test і завищують оцінки
Ворожий холдаут	Види атак, що лишаються повністю небаченими до оцінки
Рекомендаційно / тінь	Система радить; сама ніколи не блокує й не утримує

Jneopallium Ad-Fraud Guardian · Повний звіт про тестування. Результати — це докази конвеєра на детермінованому еталонному корпусі плюс слабких міток, а не твердження про реальну точність. Режим безпеки: ADVISORY / SHADOW. Ліцензія: BSD 3-Clause.